

Attività 2. Health Data Standardization Team

GRUPPO MAROLDA TEAM:

Donzelli Tommaso, Fornaciari Matteo, Gubellini Gabriele, Lonfo Zalissa, Marolda Elena

1. OBIETTIVO:

L'obiettivo principale di questa attività è standardizzare i dati all'interno di un dataset, partendo da un file csv contenente le variabili relative ai pazienti affetti da Parkinson (e non). In questo modo si può garantire interoperabilità e integrazione con altri sistemi sanitari.

2. MATERIALI E METODI:

2.1 MATERIALE UTILIZZATO

Per la realizzazione del progetto abbiamo utilizzato:

- 2 articoli suggeriti dal professore e dal tutor per inquadrare meglio obiettivi e richieste del progetto:

Towards real-world clinical data standardization: A modular FHIR-driven transformation pipeline to enhance semantic interoperability in healthcare
(<https://pubmed.ncbi.nlm.nih.gov/39904102/>)

FHIR-standardized data collection on the clinical rehabilitation pathway of trans-femoral amputation patients
(<https://www.nature.com/articles/s41597-024-03593-6>)

- **Visual Studio Code** per scrivere e visualizzare i codici;
- **FHIR MapBuilder** per visualizzare meglio i file di estensione .map;
- Il **dataset** utilizzato è reperibile sulla piattaforma Synapse:
<https://www.synapse.org/Synapse:syn55052683>
In particolare, sono stati presi in considerazione i seguenti file CSV:
 - PD - Demographic+Clinical - datasetV1
 - CONTROLS - Demographic+Clinical - datasetV1
 - HC100.Balance
 - NLS002.Balance
- Sito di **HL7 FHIR R4** (<https://www.hl7.org/fhir/R4/>) per l'individuazione dei campi e delle risorse più adeguate;

- Siti di ricerca di 3 ontologie standard:
LOINC (<https://loinc.org/search/>);
SNOMED CT (<https://snomedbrowser.org/>);
ICD (<https://www.icd10data.com/>);
- **Docker** e repository **GitHub**
(<https://github.com/albertomarfoglia/FHIR-mapping-pipeline>) per l'installazione e l'avviamento della pipeline;
- **Copilot M365** come assistente AI.

2.2 STRUTTURA DELLA PIPELINE

È stata utilizzata la pipeline di conversione automatica descritta nel repository GitHub:
<https://github.com/albertomarfoglia/FHIR-mapping-pipeline>

Questa genera una rappresentazione standardizzata del dataset in formato FHIR.

La cartella di studio è "weargaitpd", organizzata in più sottocartelle:

- **00-input:** adibita all'inserimento dei CSV:
 - *PD - Demographic+Clinical - datasetV1*;
 - *CONTROLS - Demographic+Clinical - datasetV1*;
 - Cartella "**balance_files**" con i file di più pazienti, relativi allo stato "Balance".
- **01-refinement:** dedicata all'aggiunta di script per pulire i CSV (rimuovere colonne di troppo, spazi e maiuscole) e ai file intermedi generati.
 - **Scripts:** contiene:
 - *data_cleaning.jpynb*: con istruzioni Python di rifinitura;
 - *data_cleaning.whitelist*: con variabili selezionate e nomi "ripuliti";
 - *data_cleaning.types*: con i tipi di dato delle variabili selezionate.
 - **Clean:** contiene file CSV puliti.
 - **Json:** contiene file JSON intermedi (generati con le istruzioni in csv-to-json).
- **02-mapping:** a sua volta suddivisa in:
 - indexes** → contiene:
 - *conversion-index*: specifica collegamento .map e json intermedi;
 - *csv-to-json-index*: specifica conversione CSV puliti in json intermedi (collegando i CSV ai file di struttura).
 - structures** → contiene i file di struttura per costruire i json intermedi da associare al mapping:
 - *BalanceFirstOverview, ControlsFirstOverview, PdFirstOverview*: file principali con collegamento agli altri di struttura che contengono le variabili;
 - Gli altri 9 più specifici (es: dati demografici di observation; dati relativi ai pazienti ecc.).
 - resources** → contiene:

- **Questionnaire**: viene definito il questionario MDSUPDRS;
- **CodeSystem**: con i codici locali (1 per i device e 1 per variabili di observation e varie);
- **ValueSet**: per selezionare i codici utili per ConceptMap (1 per i device, 1 per le observation, 1 per i questionari);
- **ConceptMap**: per associare codici standard reali ai codici locali (1 per device, 1 per observation, 1 per questionnaire).

mapping → contiene i file .map con le istruzioni per mappare le variabili, ovvero “il cuore del progetto”:

- *PdFirstOverviewToBundle* e *ControlsFirstOverviewToBundle* con le istruzioni per creare un bundle, relativo al singolo paziente, contenente tutte le risorse associate alle variabili relative ad esso;
- *BalanceFirstOverviewToBundle* con le istruzioni per creare un bundle, per ogni istante di tempo, contenente tutte le risorse associate alle variabili relative a quell'istante e al singolo paziente (sono stati presi solo i primi 3 istanti per non appesantire il .zip).

- **03-publishing**: contiene **bundles** ed **export** generati dalla pipeline.
- **04-validation**: contiene **validation-queries-test** (query di verifica varie).

2.3 PRINCIPI DI FUNZIONAMENTO E SCALETTA DEL LAVORO SVOLTO:

- 1) Abbiamo analizzato la struttura della Pipeline e i CSV da fornire in input. Grazie alla Wiki del dataset e alcune ricerche sul sito MDS abbiamo compreso il significato delle variabili analizzate.
- 2) È stato utilizzato il sito HL7 FHIR R4 per trovare corrispondenza tra le variabili nei file del dataset e le risorse alle quali mappare. Delle tante variabili nei CSV, abbiamo selezionato solo quelle ritenute più significative (presenti nel file di whitelist). A ciascuna è stata associata la risorsa FHIR considerata più opportuna, con alcuni dei campi relativi.
Abbiamo utilizzato le risorse: Bundle, Patient, Practitioner, Encounter, MedicationStatement, Medication, Observation, QuestionnaireResponse, Condition, Device, Questionnaire, CodeSystem, ValueSet, ConceptMap.
- 3) Abbiamo cercato i codici standard da associare ai dati, relativi alle ontologie LOINC, SNOMED, ICD.

Per alcune variabili biomeccaniche abbiamo utilizzato più ontologie:

- il codice LOINC, associato al codice locale “lowerbackaccx”, per descrivere la misurazione.
- il codice SNOMED, associato al campo Observation.bodySite per la parte del corpo in cui è stata misurata.

Per esempio, la colonna **LowerBackAccX** del file HC100_Balance:

- codice SNOMED **Lower Back 37822005**;
- codice LOINC **Activity Level (Acceleration) 80493-9**, associato al codice locale "lowerbackaccx".

- 4) Sono stati scaricati i file utili e installati i requirements. È stato tutto impostato come da indicazioni (vedere sezione **Struttura della Pipeline**).
- 5) Debugging: avendo usato una struttura organizzata, è stato semplice trovare i vari errori associati a sintassi e semantica nel codice. Procedendo con un'implementazione "a blocchi", si è aggiunta una risorsa per volta verificando il funzionamento.
- 6) All'avvio della pipeline (con docker, [main.sh](#)) si validano le risorse: se corrette, il tutto viene caricato su un server locale.

3. PROBLEMI

Nel corso del lavoro abbiamo riscontrato alcune difficoltà:

- Nei file CSV veniva specificata l'età del paziente (variabile Age), ma non la sua data di nascita. Per questo, non è stato possibile mapparla con il campo "birthDate" della risorsa Patient. Si è quindi deciso di trattarla come Observation.
- Alcuni codici di ontologia standard non avevano completa corrispondenza con le variabili da mappare. Questo ha richiesto la creazione di CodeSystem, ValueSet e ConceptMap.
- Nei CSV è presente la variabile Current Medication, una stringa contenente tutti i farmaci attualmente presi dal paziente. Sarebbe stato possibile separare le colonne per farmaco, dose, modalità di assunzione e frequenza, associando le risorse corrispondenti. Questo avrebbe comportato una maggior complessità al codice, oltre che una dilatazione delle tempistiche. Per questo, abbiamo mappato la variabile con Medication Statement e Medication, per visualizzarla come testo e associargli un codice standard LOINC (sebbene non sia al 100% corretto).
- In merito alle risposte ai Questionari, sarebbe stato possibile creare una distinzione con più codici. In particolare, si poteva associare una gravità corrispondente al valore della risposta (0→4).
Non avendo un codice LOINC specifico, il problema si risolverebbe creando dei codici locali, in modo analogo a FootContact ('Booleano' in Balance 0=NO, 1=SI) . Tuttavia, questo non è stato fatto per ripetitività.
- File pipeline modificati per compatibilità (modifiche per compatibilità con windows consigliate dal tutor).
- La presenza di tanti istanti di campionamento per singolo paziente richiede altrettanti bundle, che appesantiscono il progetto. Per semplicità sono stati considerati solo 3 istanti.

4. CONCLUSIONI

L'output del nostro lavoro deve poi essere utilizzato dal gruppo 3. Oltre ai bundle generati per singolo paziente e il server in cui si possono esplorare le varie risorse, sono stati generati i bundle per ogni istante di tempo delle misurazioni effettuate sul singolo paziente (in questo caso 3).

Una lettura di file specifici per singoli pazienti avrebbe facilitato la loro attività, implicando tuttavia la generazione di molti file di output e un processo di cleaning più complesso. Sebbene non corrispondente alla loro richiesta, un'alternativa è creare file intermedi con tutti i dati del balance, hurried pace, per un totale di solo 8 file. Questo è stato fatto per i balance sopra citati, ed è analogo per gli altri.